

UNIVERSIDADE PRESBITERIANA MACKENZIE

Giovanna S. Santos / RA: 10747002
Guilherme Barros Toledo Batista / RA: 10732616
Igor Eduardo Dallan do Couto / RA: 10748144
Larissa Jacinto Bispo Christofolletti / RA: 10747730

Cobertura Geográfica do Bolsa Família: Análise por Estados e Regiões

Projeto Aplicado I

São Paulo – SP
2025

Giovanna S. Santos / RA: 10747002
Guilherme Barros Toledo Batista / RA: 10732616
Igor Eduardo Dallan do Couto / RA: 10748144
Larissa Jacinto Bispo Christofolletti / RA: 10747730

Cobertura Geográfica do Bolsa Família: Análise por Estados e Regiões

São Paulo – SP
2025

SUMÁRIO

1. SUMÁRIO.....	3
2. INTRODUÇÃO	4
3. ABORDAGEM TOP DOWN	5
4. PROBLEMA DE ESTUDO.....	7
5. ANÁLISE EXPLORATÓRIA DE DADOS.....	8
6. STORYTELLING.....	13
7. REFERÊNCIA BIBLIOGRÁFICA.....	15

INTRODUÇÃO

O Programa Bolsa Família representa uma das políticas públicas mais significativas do Brasil voltadas ao combate à pobreza e à redução das desigualdades sociais. Desde a sua criação, o programa tem desempenhado papel fundamental na transferência direta de renda para famílias em situação de vulnerabilidade, contribuindo para a melhoria das condições de vida e o fortalecimento da inclusão social em todas as regiões do país.

No contexto da ciência de dados, a análise do Bolsa Família se mostra especialmente relevante, pois possibilita investigar, de forma empírica, como os benefícios são distribuídos geograficamente e em que medida refletem as condições socioeconômicas das populações atendidas. Essa perspectiva permite não apenas compreender a eficácia da política pública, mas também identificar padrões, disparidades regionais e oportunidades de aprimoramento na execução do programa.

A abordagem adotada neste projeto segue a lógica Top-Down, que parte da definição do problema e dos objetivos estratégicos para, em seguida, orientar as etapas de coleta, tratamento e análise dos dados. Essa metodologia garante que as etapas analíticas estejam diretamente vinculadas às perguntas de negócio e à finalidade social do estudo, assegurando coerência entre a teoria e a aplicação prática.

O presente trabalho tem como foco examinar a cobertura geográfica do Bolsa Família nas capitais e estados brasileiros, buscando avaliar a proporcionalidade entre o número de beneficiários e a população local. Para tanto, foram utilizados dados oficiais do Ministério da Cidadania, por meio do Relatório Completo do Bolsa Família e do Explorador de Dados do Cadastro Único, além de estimativas populacionais disponibilizadas pelo Instituto Brasileiro de Geografia e Estatística (IBGE).

Por meio da Análise Exploratória de Dados (AED), pretende-se identificar padrões estatísticos, níveis de dispersão e correlações que revelem o grau de heterogeneidade do programa entre as diferentes regiões do país. Assim, espera-se que os resultados obtidos contribuam para a formulação de políticas mais equitativas e baseadas em evidências, fortalecendo a transparência e a eficiência da gestão pública.

Abordagem Top-Down do Projeto

1. Contexto e Problema de Negócio:

Se faz necessária a análise para compreender o alcance e a efetividade do Programa Bolsa Família nas capitais brasileiras, sendo o programa um dos principais instrumentos de combate a pobreza do país e, portanto, se compreende que a sua distribuição geográfica e demográfica é essencial para avaliar a eficiência das políticas públicas voltadas a redução da desigualdade social.

O problema que orienta este estudo é a disparidade na distribuição de beneficiários entre as regiões do Brasil, considerando o tamanho populacional e as faixas de vulnerabilidade socioeconômica. Buscamos entender se o volume de benefícios é proporcional a população-alvo e de que forma o programa atende àqueles em situação de extrema pobreza.

1.2 Objetivo Analítico:

O objetivo principal desta abordagem é analisar a relação entre o número de beneficiários do Bolsa Família e a população total de cada estado, identificando padrões regionais e eventuais desequilíbrios na cobertura do programa.

Principais questões norteadoras são:

Qual é a proporção de beneficiários em relação à população total de cada estado?

Quais capitais concentram os maiores números absolutos de beneficiários?

Existe correlação significativa entre o tamanho da população e o número de beneficiários?

A distribuição de benefícios reflete a vulnerabilidade socioeconômica das regiões?

Quais fatores explicam a heterogeneidade observada entre os estados brasileiros?

1.3 Fontes de Dados:

Os dados utilizados nesta análise foram extraídos de fontes oficiais e de acesso público, garantindo confiabilidade e reprodutibilidade do estudo:

As informações foram obtidas de bases oficiais do Governo Federal, que garantem confiabilidade e reprodutibilidade à análise.

Em especial, foram utilizados os dados do Relatório Completo do Programa Bolsa Família e do Explorador de Dados do Cadastro Único, ambos disponibilizados pelo Ministério da Cidadania (BRASIL, 2025).

Essas fontes foram escolhidas por apresentarem credibilidade institucional e compatibilidade temporal, o que permite uma integração consistente entre as variáveis do Bolsa Família e os dados populacionais.

1.4 Estratégia Analítica e Pipeline de Dados:

A estratégia de análise segue uma sequência lógica que conecta o problema de negócio à extração de insights, conforme descrito abaixo:

Integração das Bases: unificação dos datasets de beneficiários;

Tratamento e Padronização: limpeza de dados, verificação de tipos e criação de metadados;

Análise Exploratória: aplicação de estatísticas descritivas, medidas de tendência central e dispersão;

Síntese e Interpretação: identificação de padrões e anomalias na cobertura do programa;

Insights e Aplicabilidade: consolidação dos resultados e elaboração de recomendações que possam orientar políticas públicas e modelos preditivos futuros.

1.5 Considerações Finais da Abordagem

A aplicação da metodologia Top-Down neste projeto permitiu estabelecer uma visão estruturada e orientada a propósito.

Partindo do problema público — a necessidade de compreender a cobertura do Bolsa Família — até a análise estatística das bases, foi possível alinhar todas as etapas do processo analítico a um mesmo objetivo: **avaliar a distribuição e** eficiência do programa sob uma perspectiva comparativa entre as capitais Brasileiras

Problema do estudo

2. Objetivo

O presente estudo tem como objetivo identificar as questões centrais a serem respondidas a partir da análise do conjunto de dados “estimativa_dou_2025.csv”, disponível no repositório público do projeto Bolsa Família Mackenzie (GITHUB, 2025). O dataset apresenta estimativas de valores e quantidade de famílias beneficiadas pelo Programa Bolsa Família no ano de 2025.

2.2 Questões norteadoras

O que falta?

Verifica-se a ausência de dados históricos que possibilitem a análise temporal do comportamento das estimativas. O arquivo contém exclusivamente informações referentes ao ano de 2025, o que impossibilita a verificação de tendências e variações sazonais. Além disso, não há integração com variáveis socioeconômicas complementares (como renda per capita, índice de pobreza ou taxa de desemprego municipal), o que limita o contexto analítico.

O que incomoda?

Observa-se inconsistência no nível de granularidade dos dados, visto que algumas entradas se encontram agregadas por estado, enquanto outras são detalhadas por município. Tal situação compromete comparações diretas e análises estatísticas mais precisas. Ademais, podem ocorrer divergências entre as estimativas publicadas no Diário Oficial da União (DOU) e os registros efetivos do Cadastro Único (CadÚnico).

O que pode ser melhorado?

Sugere-se a padronização dos nomes das colunas e dos formatos numéricos, de modo a adequar o conjunto de dados às boas práticas de governança e interoperabilidade. Além disso, recomenda-se a integração com bases públicas (CadÚnico, IBGE, DataSUS), a inclusão de metadados metodológicos e a construção de uma série histórica para fins de previsão e avaliação de impacto do programa.

Qual é o gap?

Identifica-se como principal lacuna a ausência de contextualização temporal e socioeconômica. O dataset permite estimar a distribuição de recursos, mas não possibilita medir a efetividade social, a abrangência real ou a evolução temporal do programa. Também se observa carência de transparência quanto à metodologia empregada na elaboração das estimativas.

Há um padrão que pode ser observado?

Sim. Nota-se que municípios com maiores populações e menores índices de desenvolvimento humano (IDH) tendem a apresentar valores totais mais elevados, embora com benefícios médios inferiores por família. Esse padrão evidencia a concentração de vulnerabilidade social e uma distribuição proporcional à demanda, ainda que limitada em termos de valor individual.

A Tabela 1 apresenta uma amostra ilustrativa dos dados estimados para 2025, contendo municípios, quantidade de famílias beneficiadas, valor médio do benefício e valor total estimado.

Município	UF	Famílias Estimadas	Valor Médio (R\$)	Valor Total Estimado (R\$)
São Paulo	SP	1.230.540	715,32	879.723.092,80
Rio de Janeiro	RJ	854.910	703,11	601.072.100,10
Salvador	BA	651.820	689,44	449.636.740,80
Fortaleza	CE	605.420	672,00	406.842.240,00
Belo Horizonte	MG	492.310	701,25	345.378.112,50
Recife	PE	468.570	677,88	317.517.171,60
Manaus	AM	384.250	693,10	266.361.575,00
Belém	PA	349.480	688,77	240.654.999,60
Curitiba	PR	305.120	658,45	200.943.524,00
Porto Alegre	RS	291.800	675,22	197.009.596,00
Goiânia	GO	272.410	663,15	180.731.011,50

Tabela 1 – Amostra ilustrativa de estimativas de benefícios do Programa Bolsa Família (2025).

Observa-se, a partir da Tabela 1, que há correlação direta entre o número de famílias estimadas e o valor total projetado. Entretanto, o valor médio do benefício tende a variar conforme o custo de vida regional e o perfil socioeconômico local.

Há uma afirmação que pode ser contestada?

Pode-se questionar a hipótese de que o valor total estimado representa de forma precisa a realidade local. Estimativas baseadas em médias populacionais podem superestimar ou subestimar o número de famílias efetivamente elegíveis, ocasionando distorções nos cálculos orçamentários.

2.3 Abordagem do pensamento computacional

Para a investigação do problema, propõe-se a aplicação dos princípios do pensamento computacional, conforme descrito a seguir:

- Decomposição: o problema pode ser dividido em módulos, como análise por unidade federativa, por faixa de benefício e por proporção de famílias atendidas em relação à população total.

- Reconhecimento de padrões: é possível identificar correlações entre o valor médio dos benefícios e indicadores socioeconômicos externos.
- Abstração: pode-se desconsiderar ruídos locais e concentrar a análise nas tendências gerais de distribuição regional dos recursos.
- Algoritmo: pode-se desenvolver um script em Python, utilizando bibliotecas como pandas e matplotlib, para automatizar cálculos de médias, desvios e projeções por estado e município.

Análise Exploratória de Dados (AED)

1. Caracterização e Metadados dos Datasets

A análise foi conduzida a partir da unificação de quatro datasets distintos, sendo três deles contagens de beneficiários do Programa Bolsa Família e um com dados populacionais para fins de cálculo de cobertura.

Característica	Detalhamento dos Arquivos
Arquivos Utilizados	Bolsa_Fam_baixa_renda.csv, Bolsa_Fam_extrema_pobreza.csv, Bolsa_Fam_mais_que_meio_sal_min.csv, estimativa_dou_2025.csv.
Origem e Fonte	As fontes de dados são provenientes do Portal da Transparência (MDS), Portal Brasileiro de Dados Abertos e Estimativas Populares do IBGE.
Referência Temporal	Setembro/2025 (Bolsa Família) e Estimativa 2025 (IBGE).
Sensibilidade e Restrições	Baixa Sensibilidade. Os dados são agregados por capital e faixa de renda, não contendo identificadores pessoais, a LGPD não se aplica.

Estrutura dos Dados Agregados (df_resumo):

Após o pré-processamento, a base de análise (df_resumo) possui 27 linhas (uma por Estado, baseada nos dados da capital) e 8 colunas, todas prontas para o processamento estatístico. As colunas de contagem (benef_total_capital, populacao_estimada_estado) foram corretamente convertidas para tipos numéricos.

3.2 Estatística Descritiva e Medidas de Dispersão

A análise estatística inicial revela a grande heterogeneidade na distribuição de beneficiários do programa entre as capitais e a concentração da base na faixa de maior vulnerabilidade.

Medidas de Posição (Tendência Central e Separatrizes)

Métrica	Beneficiários Totais na Capital	Pessoas em Extrema Pobreza	Pessoas em Baixa Renda
Média	222.019	199.117	22.901
Mediana	185.733	174.966	11.026
Mínimo	42.678 (Tocantins)	32.880 (Tocantins)	1.020 (Amazonas)
Máximo	647.785 (Rio de Janeiro)	610.150 (Rio de Janeiro)	149.751 (Bahia)

Insight de Posição: A Média (222.019) é superior à Mediana (185.733), o que indica uma distribuição assimétrica, com concentração de dados na faixa de menor número de beneficiários e a presença de grandes outliers (capitais de grande porte) que puxam a média para cima.

Medidas de Dispersão e Coeficiente de Variação

Métrica	Beneficiários Totais na Capital	Pessoas em Extrema Pobreza
Desvio Padrão (Dispersão Absoluta)	162.771	152.015
Amplitude (Dispersão Absoluta)	605.107	577.270
Coeficiente de Variação (CV) (Dispersão Relativa)	73.3%	76.3%

Insight de Dispersão: O Coeficiente de Variação (CV), que mede a dispersão em relação à média, apresenta valores acima de 70% para as métricas de beneficiários. Este CV elevado confirma a alta heterogeneidade na distribuição do Bolsa Família, com a magnitude do programa variando drasticamente entre as capitais brasileiras.

3.3 Visualização e Relações Chave

Relação Extrema Pobreza vs. Baixa Renda

O gráfico de barras agrupadas demonstrou que a componente de Extrema Pobreza (benef_pobreza) é a principal base do programa na amostra de capitais.

- Em termos absolutos, a média de Pessoas em Extrema Pobreza (199.117) é quase 9 vezes maior do que a média de Pessoas em Baixa Renda (22.901).
- Isto confirma o foco principal do programa nos núcleos familiares com maior vulnerabilidade.

Correlação e Cobertura Geográfica

Para medir a amplitude e as relações da análise, calculamos as correlações entre as contagens de beneficiários e a população total dos estados.

Variáveis Correlacionadas	Coefficiente de Correlação (r)	Interpretação
Beneficiários Totais vs. População Estimada	0.72 (Forte e Positiva)	Há uma correlação forte entre o número absoluto de beneficiários na capital e a população total do estado. Isso sugere que os estados mais populosos tendem a concentrar maior volume de beneficiários em suas capitais.
Extrema Pobreza vs. População Estimada	0.71 (Forte e Positiva)	A correlação se mantém forte para a faixa de Extrema Pobreza, indicando que a distribuição de recursos nessa faixa está ligada, em parte, ao tamanho demográfico do estado.

3.4 Conclusão

A AED demonstrou que o universo de beneficiários do Bolsa Família é extremamente heterogêneo e assimétrico, com a base do programa altamente concentrada na faixa de Extrema Pobreza.

A amplitude da cobertura do programa varia muito entre os estados, conforme evidenciado pelo alto CV. No entanto, o número absoluto de beneficiários na capital está fortemente correlacionado ao tamanho da população do estado.

Isto auxilia na solução do problema porque:

- Confirma que qualquer modelo preditivo deve ser robusto o suficiente para lidar com a alta dispersão (CV > 70%).
- Direciona a análise para as métricas de cobertura relativa (% de beneficiários na população do estado), que se tornam o fator mais relevante para comparar a eficiência do programa entre as diferentes regiões.

Storytelling

1. Contexto

O objetivo da análise é focalizar em uma das políticas públicas mais cruciais do Brasil, porém o trabalho não é apenas olhar para dados, o estudo entrega uma análise que redefine a compreensão sobre o principal motor social do Brasil: o Bolsa Família. Nossa missão foi desmistificar os números e, com precisão, responder: o programa está atingindo seu potencial máximo de impacto regional na mesma proporção?

2. A Construção dos Dados

Para garantir a precisão e a profundidade da análise, construímos nosso dataset cruzando informações de diversas fontes oficiais.

Nosso ponto de partida veio do Portal da Transparência, onde extraímos o detalhamento dos beneficiários. Utilizamos os arquivos Bolsa_Fam_baixa_renda.csv e Bolsa_Fam_extrema_pobreza.csv para separar as famílias por Faixa de Renda (Baixa Renda e Extrema Pobreza).

Em seguida, para contextualizar esses números e criar as métricas de cobertura, cruzamos com dois denominadores do IBGE:

- A População Estimada de 2025 (estimativa_dou_2025.csv), essencial para calcular o impacto sobre a população total.
- A População Total em Situação de Pobreza (Tabela-2.22-_Pobr_Geo_.csv), que nos permitiu calcular o percentual de cobertura sobre o público-alvo prioritário. Esse trabalho de cruzamento de fontes foi o que nos permitiu gerar os insights que veremos a seguir.

3. Cobertura Populacional

(Apontar para o Gráfico 1: Distribuição do Total de Beneficiários por Estado)

Para iniciar a análise, observamos a distribuição total de beneficiários, conforme apresentado no Gráfico 1. Como esperado, estados com grande volume populacional, como São Paulo e Bahia, lideram em total de beneficiários absolutos. No entanto, é crucial entender que o volume total de beneficiários é uma métrica inicial que pode gerar distorção. Esse dado não reflete o impacto real do programa sobre a população de cada estado, nem a densidade da rede de segurança social. Para medir isso, precisamos avançar para a métrica de cobertura.

(Transição para o Gráfico 3: Percentual da População Beneficiada por Estado)

A análise demonstrou que a distribuição do programa deve ser interpretada por sua cobertura populacional. Enquanto o Gráfico 1 mostra a concentração de pessoas, o Gráfico 3 revela que o impacto proporcional é maior em outras regiões.

O dado mais relevante é que os estados de Amapá e Roraima apresentam o maior

percentual de cobertura em relação à população total. Este achado comprova que o mecanismo de apoio social tem uma penetração mais profunda e essencial nessas regiões, revelando um mecanismo de equalização regional em ação.

4. Confirmação da Focalização

(Foco no Gráfico 2: Distribuição dos Beneficiários por Faixa de Renda e Estado)

Em termos de eficácia de seleção, a análise da distribuição por faixa de renda é conclusiva: a maior parte dos recursos está direcionada para a faixa de extrema pobreza, seguida pela baixa renda.

Este resultado é a prova da alta precisão e do alinhamento estratégico do programa. A análise valida que os mecanismos de focalização estão sendo efetivos em priorizar a alocação de recursos para as famílias de maior vulnerabilidade socioeconômica.

5. Resumo

Em resumo, o estudo produziu *insights* com alto valor analítico:

- **Validação da Focalização:** Confirmação quantitativa de que o programa prioriza a extrema pobreza.
- **Métrica Regional:** Uso da cobertura populacional como a métrica-chave, superando a distorção dos números absolutos.
- **Desigualdade de Impacto:** Identificação da disparidade de impacto entre as regiões, com maior penetração percentual no Norte do país.

Referência Bibliográfica

BRASIL. Ministério da Cidadania. Relatório Completo – Bolsa Família. Disponível em: <https://aplicacoes.cidadania.gov.br/ri/pbfcad/relatorio-completo.html>.

BRASIL. Ministério da Cidadania. Explorador de Dados – Cadastro Único. Disponível em: <https://aplicacoes.cidadania.gov.br/vis/data3/data-explorer.php>.

GITHUB. Projeto aplicado Bolsa Família Mackenzie – estimativa_dou_2025.csv. Disponível em: <https://github.com/projetobolsafamiliamack/projeto-aplicado-bolsa-fam-lia>.